LAPORAN TUGAS TAHAP KEDUA CLASSIFICATION
PEMBELAJARAN MESIN

Oleh :

Azriel Naufal Aulia (1301190374)

Adhie Rachmatullah Sugiono (1301194059)

FAKULTAS INFORMATIKA

TELKOM UNIVERSITY

BANDUNG

2021

A. Formulasi Masalah

Permasalahan yang akan diselesaikan pada tugas tahap kedua classification dengan metode supervised learning adalah memprediksi apakah pelanggan tertarik untuk membeli kendaraan baru atau tidak berdasarkan data pelanggan di dealer.

Deskripsi fitur pada dataset

penjelasan dari fitur-fitur dataset :

1. id : identitas pelanggan yang terdaftar
2. jenis_kelamin : jenis kelamin
3. umur : umur
4. SIM : kepemilikan SIM
5. kode daerah : kode daerah tempat tinggal pelanggan
6. sudah asuransi : sudah pernah asuransi / belum
7. umur kendaraan : umur kendaraan
8. kendaraan rusak : mobil pelanggan pernah rusak atau belum
9. premi : jumlah premi yang harus dibayarkan
10. kanal penjualan : kode kanal untuk menghubungi pelanggan (email, telpon, dll)
11. lama berlangganan : durasi pelanggan menjadi klien perusahaan
12. tertarik : tertarik ato ga

Deskripsi Model

Diberikan 2 file excel berisi data historis pelanggan dealer mobil yang tertarik / membeli dan tidak tertarik / tidak jadi beli mobil. data terdiri dari berbagai macam fitur.

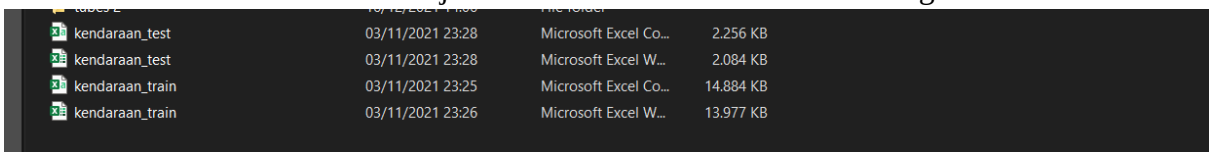

Dari dataset tersebut, akan dilakukan percobaan eksperimen model klasifikasi label pada dataset. percobaannya dimulai dari membuat model klasifikasi berdasarkan dataset pelatihan yang disediakan, kemudian dengan model klasifikasi yang dibuat akan digunakan untuk memprediksi label dari dataset testing yang telah disediakan. Dan pada akhirnya, antara hasil prediksi dan label sebenarnya dibandingkan untuk mengukur performansi dari model.

dalam percobaan membuat model klasifikasi, dengan tujuan membandingkan, kami membuat 3 model klasifikasi antara lain :

- Random Forest
- Naive Bayes
- Logistic Regression

dari ketiga model diatas cukup populer digunakan dalam kasus klasifikasi, khususnya ketika variabel independen y (label) merupakan kategorial.

Setelah dilakukan analisis terhadap label data training, dapat disimpulkan bahwa dataset merupakan *imbalanced* dataset (data tidak setara). Dimana jika di buat visualisasinya, label ‘0’ / tidak tertarik berjumlah lebih banyak dari label ‘1’/tertarik, sebesar 87% dan 12%.

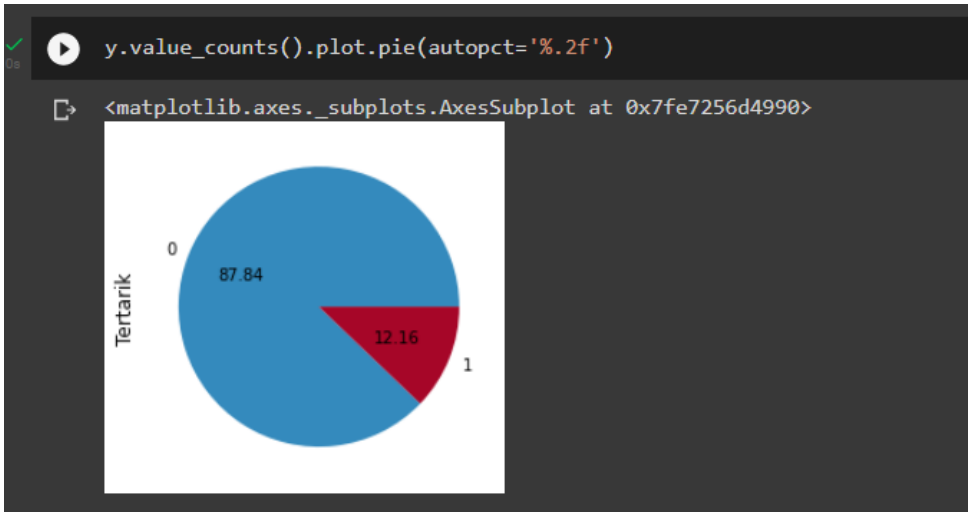

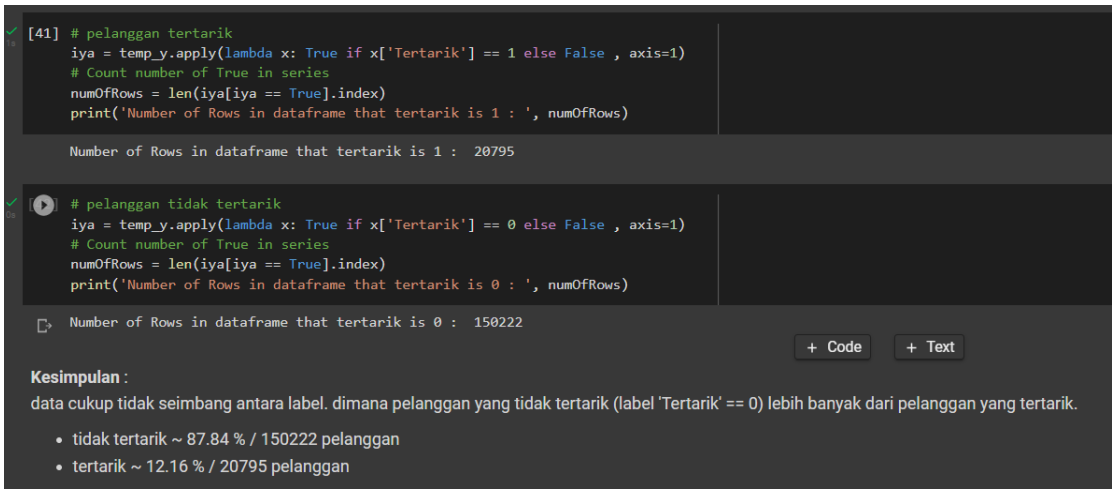

Sehingga dari kasus diatas, kami akan membuat 2 eksperimen pada dataset, melakukan overSampling dan underSampling.

Deskripsi Eksperimen

Dalam percobaan klasifikasi ini, kami melakukan 2 eksperimen pada tahap preprocessing data sebelum dimasukkan ke tahap pembuatan model,

- Eksperimen 1 :
  - mengelola nilai yang kosong (missing values) : dilakukan pembuangan pada baris tersebut.
  - label data training yang tidak setara (imbalanced dataset) : dilakukan oversampling supaya data yang setara.
- Eksperimen 2 :

- mengelola nilai yang kosong (missing values) : dilakukan pengisian nilai pada baris tersebut. pengisian nilai modus untuk data yang bersifat kategorial dan pengisian nilai rata-rata (mean) untuk data diskrit/kontinu.
- label data training yang tidak setara (imbalanced dataset) : dilakukan undersampling supaya data yang setara.

Setelah mendapatkan prediksi kami melakukan evaluasi performansi dari model dengan menghitung nilai akurasi model, nilai precision model, nilai recall model, nilai f-1 model dan membuat confusion matrix untuk melihat jumlah prediksi yang bersifat *True positive, True negative, False positive, False negative.* Dari masing-masing nilai evaluasi tersebut akan dilakukan perbandingan antara masing-masing model untuk melihat model yang memiliki performansi terbaik pada kasus ini.

B. Eksplorasi dan Persiapan data

Eksplorasi dan persiapan data yang saya lakukan pada tugas tahap kedua classification dengan metode supervised learning adalah sebagai berikut.

1. Mendrop kolom “id” karena kami mengira bahwa kolom tersebut tidak terlalu berpengaruh pada tugas classification ini.

```
1 dataTrain = dataTrain.drop(['id'], axis = 1)
```

```
1 dataTrain.head(10)
```

	Jenis_Kelamin	Umur	SIM	Kode_Daerah	Sudah_Asuransi	Umur_Kendaraan	Kendaraan_Rusak	Premi	Kanal_Penjualan	Lama_Berlangganan	Tertarik
0	Wanita	30.0	1.0	33.0	1.0	< 1 Tahun	Tidak	28029.0	152.0	97.0	0
1	Pria	48.0	1.0	39.0	0.0	> 2 Tahun	Pernah	25800.0	29.0	158.0	0
2	NaN	21.0	1.0	46.0	1.0	< 1 Tahun	Tidak	32733.0	160.0	119.0	0
3	Wanita	58.0	1.0	48.0	0.0	1-2 Tahun	Tidak	2630.0	124.0	63.0	0
4	Pria	50.0	1.0	35.0	0.0	> 2 Tahun	NaN	34857.0	88.0	194.0	0
5	Pria	21.0	1.0	35.0	1.0	< 1 Tahun	Tidak	22735.0	152.0	171.0	0
6	Wanita	33.0	1.0	8.0	0.0	NaN	Pernah	32435.0	124.0	215.0	1
7	Pria	23.0	NaN	28.0	1.0	< 1 Tahun	Tidak	26869.0	152.0	222.0	0
8	Wanita	20.0	1.0	8.0	1.0	< 1 Tahun	Tidak	30786.0	160.0	31.0	0
9	NaN	54.0	1.0	29.0	0.0	> 2 Tahun	Pernah	88883.0	124.0	28.0	1

2. Menghapus kolom yang memiliki nilai duplikat.

drop duplicate column

```
[ ]  1 duplicate = list(dataTrain.duplicated())
     2 print("Data Duplikasi :", duplicate.count(True))
```

```
Data Duplikasi : 169
```

```
[ ]  1 dataTrain.drop_duplicates(inplace=True)
```

```
[ ]  1 duplicate = list(dataTrain.duplicated())
     2 print("Data Duplikasi :", duplicate.count(True))
```

```
Data Duplikasi : 0
```

3. Mengubah nilai kategorial menjadi nilai numerik agar dapat mudah untuk dilakukannya pengolahan data. untuk tahap ini, kami menggunakan fungsi preprocessing dari library sklearn.

```
 2 from sklearn import preprocessing
```

```
 1 dataTrain.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 171017 entries, 0 to 171016
Data columns (total 11 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   Jenis_Kelamin      171017 non-null  object
 1   Umur               171017 non-null  float64
 2   SIM                171017 non-null  float64
 3   Kode_Daerah        171017 non-null  float64
 4   Sudah_Asuransi     171017 non-null  float64
 5   Umur_Kendaraan     171017 non-null  object
 6   Kendaraan_Rusak    171017 non-null  object
 7   Premi              171017 non-null  float64
 8   Kanal_Penjualan    171017 non-null  float64
 9   Lama_Berlangganan  171017 non-null  float64
 10  Tertarik           171017 non-null  int64
dtypes: float64(7), int64(1), object(3)
memory usage: 14.4+ MB
```

```
 1 # melihat berapa banyak total kategori pada jenis_kelamin, umur_kendaraan, kendaraan_rusak
 2 cols = ['Jenis_Kelamin','Umur_Kendaraan','Kendaraan_Rusak']
 3 dataTrain[cols].nunique()
```

```
Jenis_Kelamin      2
Umur_Kendaraan     3
Kendaraan_Rusak    2
dtype: int64
```

Berikut hasilnya,

```
le = preprocessing.LabelEncoder()
dataTrain[cols] = dataTrain[cols].apply(le.fit_transform)
###
# jenis kelamin : wanita/1 || pria/0
# umur kendaraan : < 1 tahun/1 || 1-2 tahun/0 || >2 tahun/2
# kendaraan rusak : tidak/1 || pernah/0
###
```

```
dataTrain.head(10)
```

	Jenis_Kelamin	Umur	SIM	Kode_Daerah	Sudah_Asuransi	Umur_Kendaraan	Kendaraan_Rusak	Premi	Kanal_Penjualan	Lama_Berlangganan	Tertarik
0	1	30.0	1.0	33.0	1.0	1	1	28029.0	152.0	97.0	0
1	0	48.0	1.0	39.0	0.0	2	0	25800.0	29.0	158.0	0
2	1	58.0	1.0	48.0	0.0	0	1	2630.0	124.0	63.0	0
3	0	21.0	1.0	35.0	1.0	1	1	22735.0	152.0	171.0	0
4	1	20.0	1.0	8.0	1.0	1	1	30786.0	160.0	31.0	0
5	0	25.0	1.0	14.0	1.0	1	1	34212.0	152.0	282.0	0
6	0	66.0	1.0	24.0	1.0	0	1	38616.0	145.0	281.0	0
7	0	31.0	1.0	8.0	0.0	1	0	2630.0	152.0	132.0	0
8	1	24.0	1.0	30.0	1.0	1	1	27285.0	152.0	215.0	0
9	1	22.0	1.0	15.0	0.0	1	0	38289.0	152.0	225.0	0

4. Melakukan normalisasi pada dataset. Pada normalisasi kami menggunakan metode normalisasi Min-Max scaler yang merubah semua range nilai menjadi range nilai dari 0 - 1.

```
from sklearn.preprocessing import MinMaxScaler
```

```
cols = ['Umur','Kode_Daerah','Premi','Kanal_Penjualan','Lama_Berlangganan']

# dataTrain = normalise_min_max(dataTrain[cols])

scaler = MinMaxScaler()

dataTrain[cols] = scaler.fit_transform(dataTrain[cols].values)
dataTrain.sample(10)
```

	Jenis_Kelamin	Umur	SIM	Kode_Daerah	Sudah_Asuransi	Umur_Kendaraan	Kendaraan_Rusak	Premi	Kanal_Penjualan	Lama_Berlangganan	Tertarik
73258	0	0.446154	1.0	0.538462	0.0	0	0	0.051937	0.759259	0.359862	0
221328	1	0.092308	1.0	0.788462	1.0	1	1	0.043298	0.932099	0.397924	0
91319	0	0.584615	1.0	0.538462	0.0	0	0	0.000000	0.759259	0.089965	0
167489	1	0.107692	1.0	0.576923	1.0	1	1	0.061596	0.981481	0.653979	0
18642	1	0.092308	1.0	0.153846	1.0	1	1	0.088309	0.932099	0.826990	0
68485	0	0.061538	1.0	0.923077	1.0	1	1	0.000000	0.932099	0.224913	0
80894	0	0.046154	1.0	0.884615	1.0	1	1	0.054108	0.932099	0.114187	0
27777	2	0.107692	1.0	0.346154	1.0	1	1	0.051937	0.932099	0.352941	0
182944	0	0.107692	1.0	0.288462	1.0	1	1	0.057127	0.932099	0.224913	0
169021	1	0.092308	1.0	0.576923	0.0	1	2	0.040191	0.932099	0.743945	0

5. Melakukan visualisasi data

- Membuat heatmap untuk melihat nilai korelasi antara masing-masing fitur.

```
plt.figure(figsize=(15, 5))
sns.heatmap(dataTrain.corr(), annot = True,linewidths=.5)
plt.title("Dataset `TRAIN`" ,y=1.1)
plt.show()

plt.figure(figsize=(15, 5))
sns.heatmap(dataTest.corr(), annot = True,linewidths=.5)
plt.title("Dataset `TEST`" ,y=1.1)
plt.show()
```

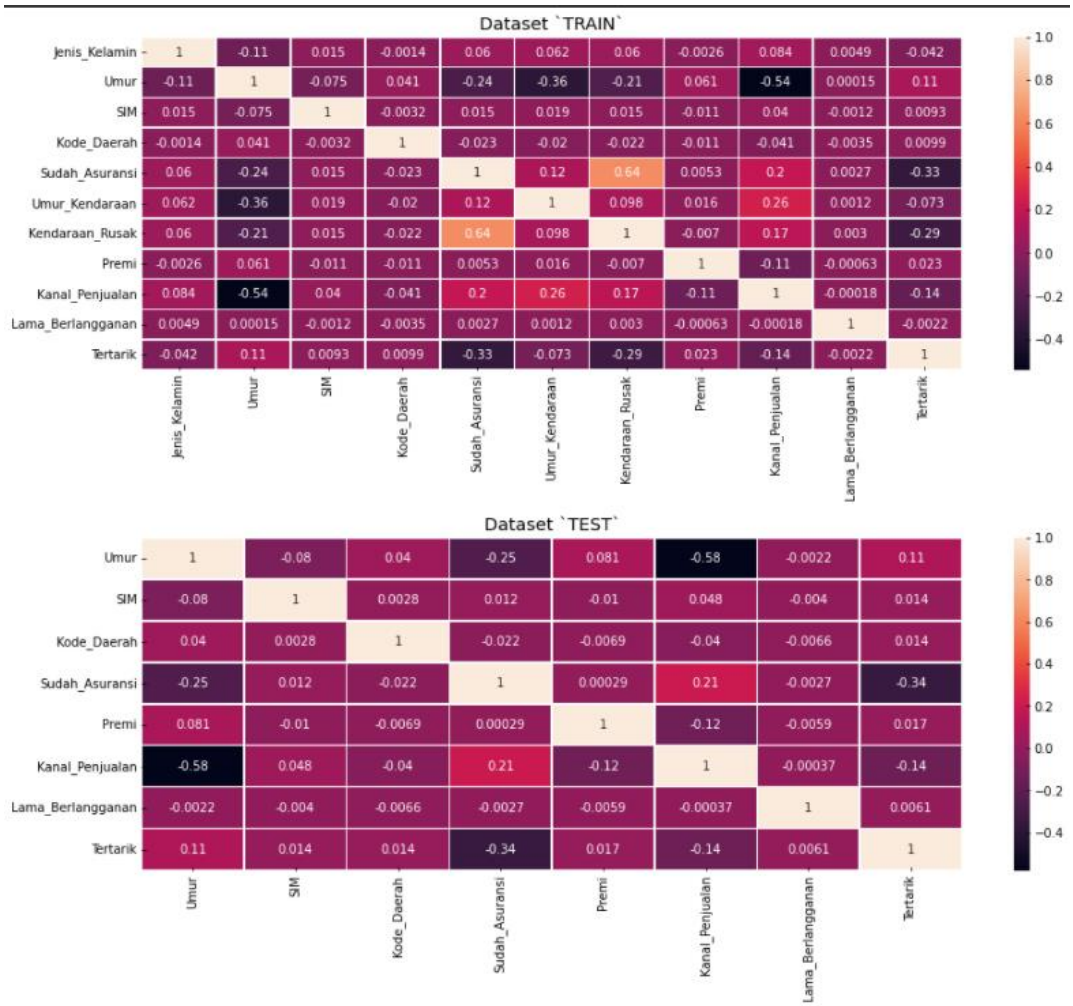

- membuat boxplot untuk mengecek outlier pada kolom premi, umur, dan lama berlangganan. (hanya tiga kolom tersebut karena kolom lainnya merupakan kategorikal)

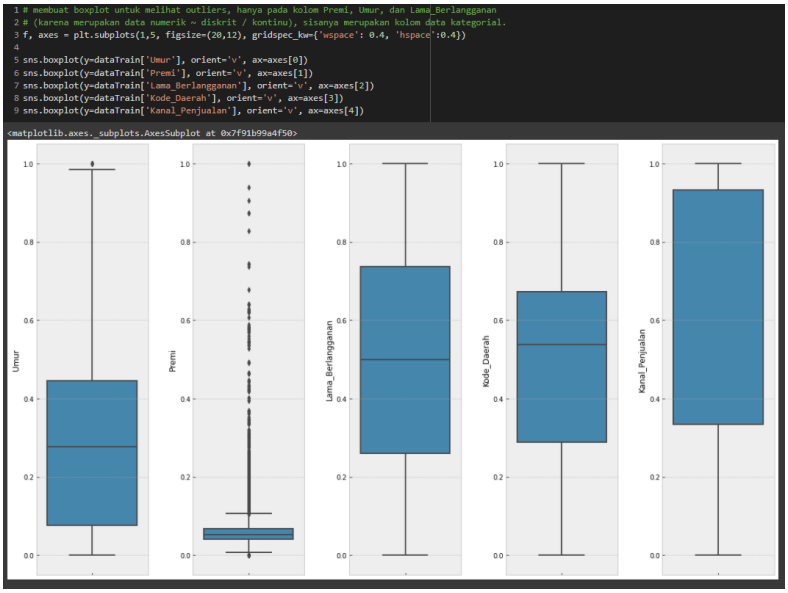

Dari hasil boxplot, dapat dilihat terdapat nilai pencilan (outlier) yang cukup banyak pada fitur ‘premi’. Namun jika kita analisa fitur ‘premi’, premi merupakan jumlah premi yang harus dibayarkan pelanggan per tahunnya, dan karena pada dataset tidak dijelaskan lebih lanjut untuk produk asuransi dari masing-masing pelanggan, maka kita tidak bisa menentukan apakah nilai pencilan pada fitur ‘premi’ merupakan nilai pencilan yang valid. Masing-masing pelanggan bisa saja membeli produk asuransi yang berbeda sehingga nilai pada fitur ‘premi’ menjadi terdistribusi merata seperti pada di boxplot. Sehingga saya memutuskan bahwa nilai pencilan (outliers) pada fitur ‘premi’ merupakan nilai yang normal dan tidak perlu untuk melakukan pembuangan outliers.

Begitu pun juga fitur ‘umur’, yang apabila pada kasus permasalahan ini (pelanggan tertarik membeli / tidak tertarik membeli), tidak melepas kemungkinan bahwa terdapat pelanggan yang cenderung lebih tua dibanding lainnya, sehingga outliers (pencilan) pada fitur ‘umur’ dianggap normal / dapat terjadi sehingga tidak perlu untuk melakukan pembuangan outliers.

C. Eksperimen

- Eksperimen 1 :
    - mengelola nilai yang kosong (missing values) : dilakukan pembuangan pada baris tersebut.

Nilai kosong (missing values) cukup tersebar.

```
import missingno as msno
msno.matrix(dataTrain)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7fe72f38edd0>
```

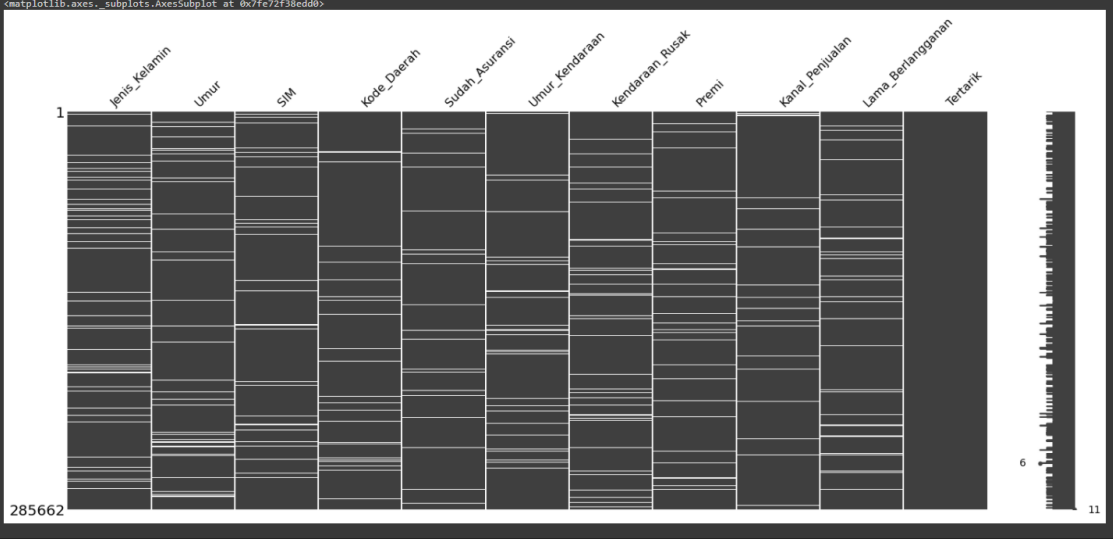

Untuk masing-masing fitur, terdapat nilai kosong sekitar 4-5%.

```
#Finding Missing values percentage in all columns
miss = pd.DataFrame(dataTrain.isnull().sum())
miss = miss.rename(columns={0:"miss_count"})
miss["miss_%"] = (miss.miss_count/len(dataTrain.index))*100
miss
```

	miss_count	miss_%
Jenis_Kelamin	14439	5.054575
Umur	14199	4.970560
SIM	14404	5.042323
Kode_Daerah	14291	5.002766
Sudah_Asuransi	14229	4.981062
Umur_Kendaraan	14275	4.997164
Kendaraan_Rusak	14187	4.966359
Premi	14510	5.079430
Kanal_Penjualan	14297	5.004866
Lama_Berlangganan	13926	4.874992
Tertarik	0	0.000000

Membuang baris yang terdapat nilai kosongnya.

```
# drop data yang ada NaN value nya
dataTrain.dropna(inplace = True)
# reset index
dataTrain.reset_index(inplace=True,drop=True)
# show data
dataTrain.head()
```

	Jenis_Kelamin	Umur	SIM	Kode_Daerah	Sudah_Asuransi	Umur_Kendaraan	Kendaraan_Rusak	Premi	Kanal_Penjualan	Lama_Berlangganan	Tertarik
0	Wanita	30.0	1.0	33.0	1.0	< 1 Tahun	Tidak	28029.0	152.0	97.0	0
1	Pria	48.0	1.0	39.0	0.0	> 2 Tahun	Pernah	25800.0	29.0	158.0	0
2	Wanita	58.0	1.0	48.0	0.0	1-2 Tahun	Tidak	2630.0	124.0	63.0	0
3	Pria	21.0	1.0	35.0	1.0	< 1 Tahun	Tidak	22735.0	152.0	171.0	0
4	Wanita	20.0	1.0	8.0	1.0	< 1 Tahun	Tidak	30786.0	160.0	31.0	0

Setelah dilakukan pembuangan baris, terdapat sekitar 40% baris yang dibuang pada dataset

```
persentase_drop = ((rows_before - rows_after)/rows_before)*100
persentase_drop
```

```
40.13309435626719
```

- label data training yang tidak setara (imbalanced dataset) : dilakukan oversampling supaya data yang setara.

untuk melakukan overSampling, kami menggunakan fungsi RandomOverSampling dari library imblearn.over_sampling

```
from imblearn.over_sampling import RandomOverSampler
```

Jumlah dataset sebelum dilakukan oversampling

```
dataTrain.shape
```

```
(171017, 10)
```

```
[46] y.shape
```

```
(171017,)
```

Melakukan overSampling

```
#ros = RandomOverSampler(sampling_strategy=1) # Float
ros = RandomOverSampler(sampling_strategy="not majority") # String
X_ros, y_ros = ros.fit_resample(dataTrain, y)

ax = y_ros.value_counts().plot.pie(autopct='%.2f')
_ = ax.set_title("Over-sampling")
```

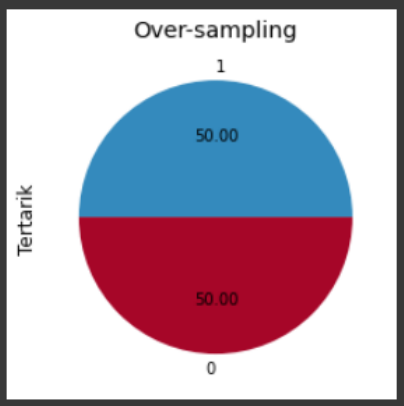

Jumlah dataset setelah dilakukan oversampling

```
[48] X_ros.shape

     (300444, 10)

     y_ros.shape

     (300444,)
```

terjadi penambahan yang cukup banyak setelah dilakukan oversampling.

- Eksperimen 2 :
    - mengelola nilai yang kosong (missing values) : dilakukan pengisian nilai pada baris tersebut. pengisian nilai modus untuk data yang bersifat kategorial dan pengisian nilai rata-rata (mean) untuk data diskrit/kontinu.

```
# jenis kelamin dengan modus
dataTrain['Jenis_Kelamin'].fillna(int(dataTrain['Jenis_Kelamin'].mode()), inplace=True)
# umur dengan mean
dataTrain['Umur'].fillna(float(dataTrain['Umur'].mean()), inplace=True)
# SIM dengan modus
dataTrain['SIM'].fillna(float(dataTrain['SIM'].mode()), inplace=True)
# kode daerah dengan modus
dataTrain['Kode_Daerah'].fillna(float(dataTrain['Kode_Daerah'].mode()), inplace=True)

# sudah asuransi dengan modus
dataTrain['Sudah_Asuransi'].fillna(float(dataTrain['Sudah_Asuransi'].mode()), inplace=True)
# umur kendaraan dengan modus
dataTrain['Umur_Kendaraan'].fillna(int(dataTrain['Umur_Kendaraan'].mode()), inplace=True)
# kendaraan rusak dengan modus
dataTrain['Kendaraan_Rusak'].fillna(int(dataTrain['Kendaraan_Rusak'].mode()), inplace=True)
# premi dengan mean
dataTrain['Premi'].fillna(float(dataTrain['Premi'].mean()), inplace=True)

# kanal penjualan dengan modus
dataTrain['Kanal_Penjualan'].fillna(float(dataTrain['Kanal_Penjualan'].mode()), inplace=True)
# lama berlangganan dengan mean
dataTrain['Lama_Berlangganan'].fillna(float(dataTrain['Lama_Berlangganan'].mean()), inplace=True)
```

Untuk mengisi nilai pada masing-masing fitur, fitur yang merupakan kategorial akan diisi dengan nilai modus pada fitur tersebut. sedangkan fitur yang merupakan numerik (diskrit/kontinu) akan diisi dengan nilai rata-rata (mean) pada fitur tersebut.

- fitur kategorial seperti fitur ‘jenis kelamin’, ‘SIM’, ‘kode daerah’, ‘sudah asuransi’, ‘umur kendaraan’, ‘kendaraan rusak’, ‘kanal penjualan’
- fitur numerik seperti fitur ‘Umur’, ‘premi’, ‘lama berlangganan’.

    - label data training yang tidak setara (imbalanced dataset) : dilakukan undersampling supaya data yang setara.

```
[42] from imblearn.under_sampling import RandomUnderSampler
```

```
dataTrain.shape

(285662, 10)

[45] y.shape

(285662,)
```

jumlah dataset sebelum dilakukan undersampling

```
[44] dataTrain.shape

(285662, 10)

y.shape

(285662,)
```

Melakukan underSampling

```
rus = RandomUnderSampler(sampling_strategy=1) # Numerical value
# rus = RandomUnderSampler(sampling_strategy="not minority") # String
X_rus, y_rus = rus.fit_resample(dataTrain, y)

ax = y_rus.value_counts().plot.pie(autopct='%.2f')
_ = ax.set_title("Under-sampling")
```

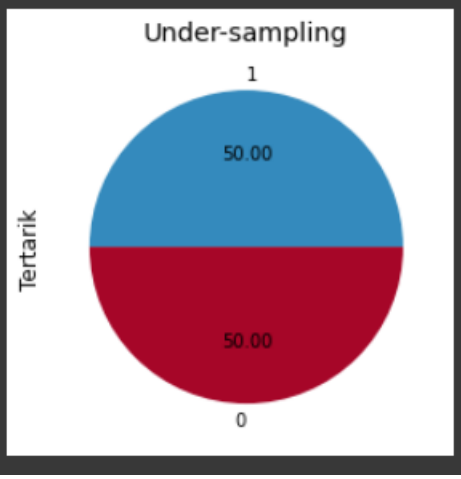

Jumlah dataset setelah underSampling

```
X_rus.shape
(70002, 10)

[48] y_rus.shape
(70002,)
```

Terjadi penurunan dataset yang cukup banyak, dari sitar 280 ribu baris menjadi 70 ribu baris (penghapusan sekitar 70 % dataset asli).

6. Mempersiapkan data training dari dataset kendaraan_train.csv dan data testing dari dataset kendaraan_test.csv

prepare data training and testing

```
[50] # X_ros
     # y_ros
```

dataTraining

```
[51] y_training = y_ros.to_numpy()
     data_training = X_ros.to_numpy()
```

```
[52] # y_training
     # data_training
```

dataTesting

```
[53] y = dataTest['Tertarik']
     dataTest = dataTest.drop('Tertarik', axis = 1)
```

```
[54] y_testing = y.to_numpy()
     data_testing = dataTest.to_numpy()
```

```
[55] # y_testing
     # data_Testing
```

dihasilkan,

- data Training yang terdiri dari data_training dan y_training untuk pembuatan model.
- data Testing yang terdiri dari data_testing dan y_testing. data_testing untuk digunakan model membuat prediksi dan y_testing untuk dijadikan penilaian dari hasil prediksi model.

D. Pemodelan

1. Decision Tree
   a. Mengimplementasikan rumus entropy

```
def entropy(y):
    hist = np.bincount(y)
    ps = hist / len(y)
    return -np.sum([p * np.log2(p) for p in ps if p > 0])
```

   b. Membuat class yang bisa menyimpan informasi node

```
class Node:
    def __init__(
        self, feature=None, threshold=None, left=None, right=None, *, value=None
    ):
        self.feature = feature
        self.threshold = threshold
        self.left = left
        self.right = right
        self.value = value

    def is_leaf_node(self):
        return self.value is not None
```

   c. Pada kodingan ini pertama melakukan deklarasi parameternya terlebih dahulu dan pada metode fit akan dilakukannya pengecekan dan pembentukan tree dari metode grow tree yang melakukan pemilihan split yang terbaik dengan metode greedy search dan membentuk lagi dari split tersebut.

```python
class DecisionTree:
    def __init__(self, min_samples_split=2, max_depth=100, n_feats=None):
        self.min_samples_split = min_samples_split
        self.max_depth = max_depth
        self.n_feats = n_feats
        self.root = None

    def fit(self, X, y):
        self.n_feats = X.shape[1] if not self.n_feats else min(self.n_feats, X.shape[1])
        self.root = self._grow_tree(X, y)

    def predict(self, X):
        return np.array([self._traverse_tree(x, self.root) for x in X])

    def _grow_tree(self, X, y, depth=0):
        n_samples, n_features = X.shape
        n_labels = len(np.unique(y))

        # stopping criteria
        if (
            depth >= self.max_depth
            or n_labels == 1
            or n_samples < self.min_samples_split
        ):
            leaf_value = self._most_common_label(y)
            return Node(value=leaf_value)

        feat_idxs = np.random.choice(n_features, self.n_feats, replace=False)

        # greedily select the best split according to information gain
        best_feat, best_thresh = self._best_criteria(X, y, feat_idxs)

        # grow the children that result from the split
        left_idxs, right_idxs = self._split(X[:, best_feat], best_thresh)
        left = self._grow_tree(X[left_idxs, :], y[left_idxs], depth + 1)
        right = self._grow_tree(X[right_idxs, :], y[right_idxs], depth + 1)
        return Node(best_feat, best_thresh, left, right)
```

```python
def _best_criteria(self, X, y, feat_idxs):
    best_gain = -1
    split_idx, split_thresh = None, None
    for feat_idx in feat_idxs:
        X_column = X[:, feat_idx]
        thresholds = np.unique(X_column)
        for threshold in thresholds:
            gain = self._information_gain(y, X_column, threshold)

            if gain > best_gain:
                best_gain = gain
                split_idx = feat_idx
                split_thresh = threshold

    return split_idx, split_thresh

def _information_gain(self, y, X_column, split_thresh):
    # parent loss
    parent_entropy = entropy(y)

    # generate split
    left_idxs, right_idxs = self._split(X_column, split_thresh)

    if len(left_idxs) == 0 or len(right_idxs) == 0:
        return 0

    # compute the weighted avg. of the loss for the children
    n = len(y)
    n_l, n_r = len(left_idxs), len(right_idxs)
    e_l, e_r = entropy(y[left_idxs]), entropy(y[right_idxs])
    child_entropy = (n_l / n) * e_l + (n_r / n) * e_r

    # information gain is difference in loss before vs. after split
    ig = parent_entropy - child_entropy
    return ig
```

```
def _split(self, X_column, split_thresh):
    left_idxs = np.argwhere(X_column <= split_thresh).flatten()
    right_idxs = np.argwhere(X_column > split_thresh).flatten()
    return left_idxs, right_idxs

def _traverse_tree(self, x, node):
    if node.is_leaf_node():
        return node.value

    if x[node.feature] <= node.threshold:
        return self._traverse_tree(x, node.left)
    return self._traverse_tree(x, node.right)

def _most_common_label(self, y):
    counter = Counter(y)
    most_common = counter.most_common(1)[0][0]
    return most_common
```

2. Random Forest
    a. Pada kodingan ini, mengambil index dari sampel yang kemudian akan mengembalikan x dan y pada indeks tersebut. Selanjutnya, kodingan most common label mencari label dari y yang paling banyak

```
from collections import Counter

import numpy as np

def bootstrap_sample(X, y):
    n_samples = X.shape[0]
    idxs = np.random.choice(n_samples, n_samples, replace=True)
    return X[idxs], y[idxs]


def most_common_label(y):
    counter = Counter(y)
    most_common = counter.most_common(1)[0][0]
    return most_common
```

    b. Pada kodingan ini, mengimplementasikan random forest yang didapatkan dari beberapa decision tree. Pertama - tama kami mendeklarasikan terlebih dahulu parameter yang akan digunakan. Lalu membuat looping yang menghasilkan decision tree yang saling berbeda dari metode sampel sebelumnya.

Selanjutnya, terdapat metode predict yang digunakan untuk mencari prediksi yang terbaik.

```
class RandomForest:
    def __init__(self, n_trees=10, min_samples_split=2, max_depth=100, n_feats=None):
        self.n_trees = n_trees
        self.min_samples_split = min_samples_split
        self.max_depth = max_depth
        self.n_feats = n_feats
        self.trees = []

    def fit(self, X, y):
        self.trees = []
        for _ in range(self.n_trees):
            tree = DecisionTree(
                min_samples_split=self.min_samples_split,
                max_depth=self.max_depth,
                n_feats=self.n_feats,
            )
            X_samp, y_samp = bootstrap_sample(X, y)
            tree.fit(X_samp, y_samp)
            self.trees.append(tree)

    def predict(self, X):
        tree_preds = np.array([tree.predict(X) for tree in self.trees])
        tree_preds = np.swapaxes(tree_preds, 0, 1)
        y_pred = [most_common_label(tree_pred) for tree_pred in tree_preds]
        return np.array(y_pred)
```

c. Pada kodingan ini kami mengubah dataset yang telah kami oleh menjadi bentuk array agar bisa digunakan untuk model Random Forest

```
[ ]  clf = RandomForest(n_trees=3, max_depth=10)

[ ]  clf.fit(data_training, y_training)

[ ]  y_pred_rf = clf.predict(data_testing)

[ ]  def accuracy(y_true, y_pred):
       accuracy = np.sum(y_true == y_pred) / len(y_true)
       return accuracy

[ ]  acc = accuracy(y_testing, y_pred_rf)

     print("Accuracy:", acc)

     Accuracy: 0.6899808980037364
```

3. Naive Bayes
    a. Pada bagian ini pertama - tama kami mengimplementasikan prior probability untuk digunakan pada metode fit seperti menghitung mean, var, dan prior. Setelah itu, kodingan tersebut akan mengimplementasikan perhitungan posterior probability dan class conditional yang setelahnya akan dipilih class yang memiliki probabilitas yang tertinggi.

```
class NaiveBayes:
    def fit(self, X, y):
        n_samples, n_features = X.shape
        self._classes = np.unique(y)
        n_classes = len(self._classes)

        # calculate mean, var, and prior for each class
        self._mean = np.zeros((n_classes, n_features), dtype=np.float64)
        self._var = np.zeros((n_classes, n_features), dtype=np.float64)
        self._priors = np.zeros(n_classes, dtype=np.float64)

        for idx, c in enumerate(self._classes):
            X_c = X[y == c]
            self._mean[idx, :] = X_c.mean(axis=0)
            self._var[idx, :] = X_c.var(axis=0)
            self._priors[idx] = X_c.shape[0] / float(n_samples)

    def predict(self, X):
        y_pred = [self._predict(x) for x in X]
        return np.array(y_pred)

    def _predict(self, x):
        posteriors = []

        # calculate posterior probability for each class
        for idx, c in enumerate(self._classes):
            prior = np.log(self._priors[idx])
            posterior = np.sum(np.log(self._pdf(idx, x)))
            posterior = prior + posterior
            posteriors.append(posterior)

        # return class with highest posterior probability
        return self._classes[np.argmax(posteriors)]

    def _pdf(self, class_idx, x):
        mean = self._mean[class_idx]
        var = self._var[class_idx]
        numerator = np.exp(-((x - mean) ** 2) / (2 * var))
        denominator = np.sqrt(2 * np.pi * var)
        return numerator / denominator
```

b. Pada kodingan ini, kami membuat model dan melakukan perhitungan akurasi dari pemodelan yang telah dijalankan

```
nb = NaiveBayes()
nb.fit(data_training, y_training)
```

```
y_pred_nb = nb.predict(data_testing)
```

```
def accuracy(y_true, y_pred):
    accuracy = np.sum(y_true == y_pred) / len(y_true)
    return accuracy
```

```
acc = accuracy(y_testing, y_pred_nb)

print("Accuracy:", acc)
```

```
Accuracy: 0.5820651147169336
```

4. Logistic Regression
   a. Pada kodingan ini, pertama - tama kami mendeklarasikan parameter yang akan digunakan, lalu kita mengimplementasikan looping gradient descent yang pertama menggunakan approximation yang telah diimplementasikan dan mengaplikasikan fungsi sigmoid yang telah dideklarasikan. Setelah itu, kami mengoperasikan gradien dan meng update parameter.

```python
class LogisticRegression:
    def __init__(self, learning_rate=0.001, n_iters=1000):
        self.lr = learning_rate
        self.n_iters = n_iters
        self.weights = None
        self.bias = None

    def fit(self, X, y):
        n_samples, n_features = X.shape

        # init parameters
        self.weights = np.zeros(n_features)
        self.bias = 0

        # gradient descent
        for _ in range(self.n_iters):
            # approximate y with linear combination of weights and x, plus bias
            linear_model = np.dot(X, self.weights) + self.bias
            # apply sigmoid function
            y_predicted = self._sigmoid(linear_model)

            # compute gradients
            dw = (1 / n_samples) * np.dot(X.T, (y_predicted - y))
            db = (1 / n_samples) * np.sum(y_predicted - y)
            # update parameters
            self.weights -= self.lr * dw
            self.bias -= self.lr * db

    def predict(self, X):
        linear_model = np.dot(X, self.weights) + self.bias
        y_predicted = self._sigmoid(linear_model)
        y_predicted_cls = [1 if i > 0.5 else 0 for i in y_predicted]
        return np.array(y_predicted_cls)

    def _sigmoid(self, x):
        return 1 / (1 + np.exp(-x))
```

b. Pada kodingan ini, kami membuat model dan melakukan perhitungan akurasi dari pemodelan yang telah dijalankan

```
[ ]  regressor = LogisticRegression(learning_rate=0.0001, n_iters=1000)
     regressor.fit(data_training, y_training)

     def accuracy(y_true, y_pred):
       accuracy = np.sum(y_true == y_pred) / len(y_true)
       return accuracy

[ ]  y_pred_lr = regressor.predict(data_testing)

     print("LR classification accuracy:", accuracy(y_training, y_pred_lr))
```

E. Evaluasi Model

untuk meng-evaluasi model klasifikasi yang telah dibuat, kami menggunakan metode evaluasi seperti :

- Nilai akurasi model

Nilai akurasi model menunjukkan berapa banyak prediksi yang benar.

$$Accuracy = \frac{Number\ of\ correct\ predictions}{Number\ of\ all\ predictions}$$

Namun nilai akurasi model sendiri tidak bisa menunjukkan apakah model cukup optimal. Dikarenakan nilai akurasi 90 % pada suatu model dianggap tidak optimal apabila pada dataset ternyata terdapat kategori label terdiri dari 90% label A dan 10 % label B (dataset tidak setara / *imbalanced dataset*). oleh karena itu, Dalam kasus ini, kami membutuhkan metrik lain untuk mengevaluasi model.

- Nilai dari precision and recall

Precision menunjukan seberapa bagus model kita ketika prediksinya positif.

$$Precision = \frac{TP}{TP + FP}$$

sedangkan, recall adalah seberapa baik model kami dalam memprediksi kelas positif dengan benar.

$$Recall = \frac{TP}{TP + FN}$$

- F1 score

F1 score adalah weighted average dari nilai precision dan recall.

$$F1\_score = 2\frac{Precision * Recall}{Precision + Recall}$$

- confusion matrix

Confusion matrix bukanlah metrik untuk mengevaluasi model, tetapi memberikan wawasan tentang prediksi. bentuk dari confusion matrix seperti sebagai berikut,

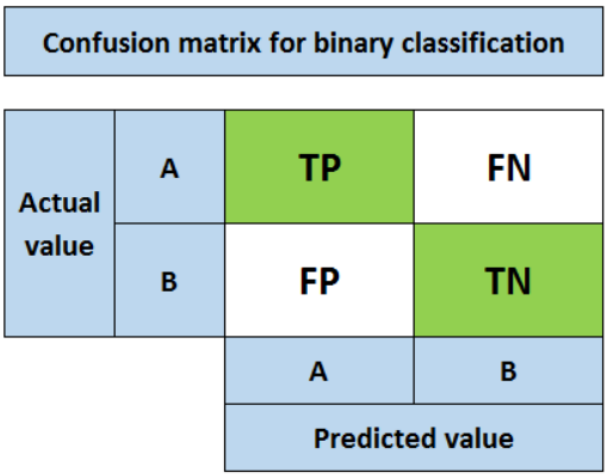

Dengan melihat confusion matrix, kita dapat menganalisa jumlah,

- True Positive (TP), memprediksi kelas A sebagai kelas A
- True Negative (TN), memprediksi kelas B sebagai kelas B
- False Positive (FP), memprediksi kelas B sebagai kelas A
- False Negative (FN), memprediksi kelas A sebagai kelas B

untuk menghitung nilai evaluasi diatas, kami menggunakan library sklearn yang sudah terdapat fungsi khusus untuk menghitungnya.

```
from sklearn.metrics import confusion_matrix, accuracy_score, precision_score, recall_score, f1_score
```

Evaluasi model dari eksperimen 1

- **nilai akurasi model, nilai precision model, nilai recall model, nilai f-1 model dan confusion matrix**

Model random forest

```
[73] # random forest
     accuracy_rf = accuracy_score(y_testing, y_pred_rf)
     precision_rf = precision_score(y_testing, y_pred_rf)
     recall_rf =  recall_score(y_testing, y_pred_rf)
     f1_rf = f1_score(y_testing, y_pred_rf)
     print("evaluasi random forrest")
     print('accuracy_random_Forest : %.3f' %accuracy_rf)
     print('precision_random_Forest : %.3f' %precision_rf)
     print('recall_random_Forest : %.3f' %recall_rf)
     print('f1-score_random_Forest : %.3f' %f1_rf)
```

```
evaluasi random forrest
accuracy_random_Forest : 0.694
precision_random_Forest : 0.277
recall_random_Forest : 0.928
f1-score_random_Forest : 0.427
```

```
# confusion matrix random forrest
cm = confusion_matrix(y_testing, y_pred_rf)
p = sns.heatmap(pd.DataFrame(cm), annot=True, cmap="YlGnBu" ,fmt='g')
plt.title('confusion matrix for random forrest')
plt.xlabel('Predicted Label')
plt.ylabel('actual label')
plt.show()
```

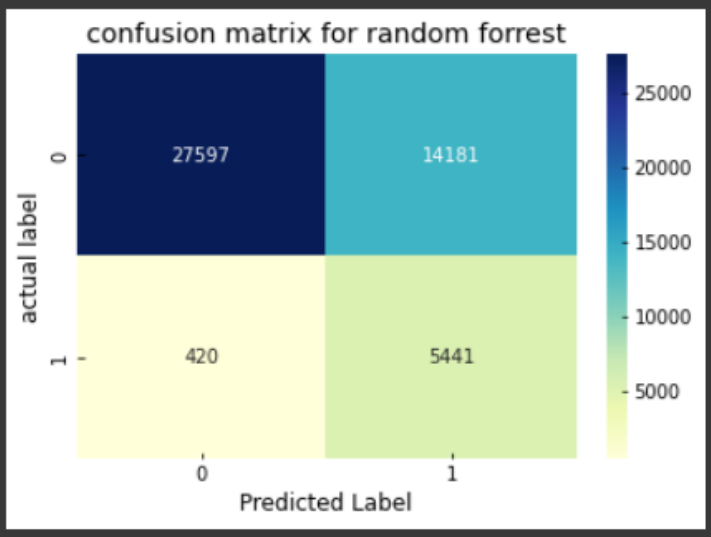

Model naive bayes

```
# naive bayes
accuracy_nb = accuracy_score(y_testing, y_pred_nb)
precision_nb = precision_score(y_testing, y_pred_nb)
recall_nb =  recall_score(y_testing, y_pred_nb)
f1_nb = f1_score(y_testing, y_pred_nb)
print("evaluasi naive bayes")
print('accuracy_random_Forest : %.3f' %accuracy_nb)
print('precision_random_Forest : %.3f' %precision_nb)
print('recall_random_Forest : %.3f' %recall_nb)
print('f1-score_random_Forest : %.3f' %f1_nb)
```

```
evaluasi naive bayes
accuracy_random_Forest : 0.640
precision_random_Forest : 0.251
recall_random_Forest : 0.975
f1-score_random_Forest : 0.400
```

```
# confusion matrix naive bayes
cm = confusion_matrix(y_testing, y_pred_nb)
p = sns.heatmap(pd.DataFrame(cm), annot=True, cmap="YlGnBu" ,fmt='g')
plt.title('confusion matrix for naive bayes')
plt.xlabel('Predicted Label')
plt.ylabel('actual label')
plt.show()
```

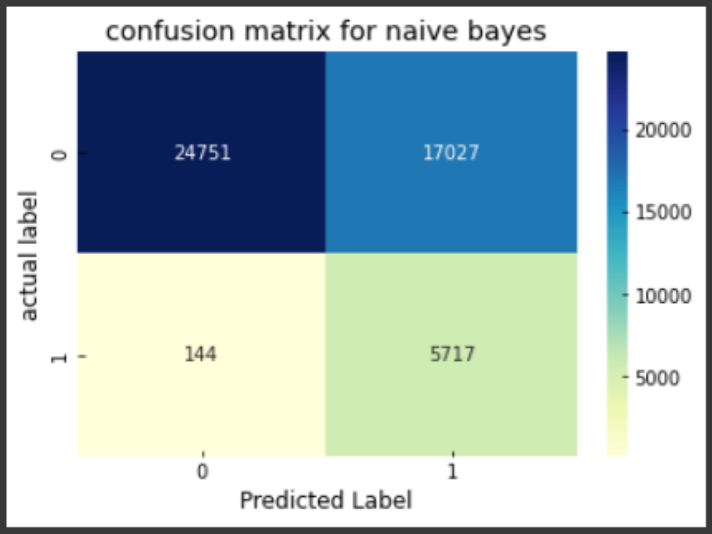

Model logistic regression

```python
# logistic regression
accuracy_lr = accuracy_score(y_testing, y_pred_lr)
precision_lr = precision_score(y_testing, y_pred_lr)
recall_lr =  recall_score(y_testing, y_pred_lr)
f1_lr = f1_score(y_testing, y_pred_lr)
print('accuracy_random_Forest : %.3f' %accuracy_lr)
print('precision_random_Forest : %.3f' %precision_lr)
print('recall_random_Forest : %.3f' %recall_lr)
print('f1-score_random_Forest : %.3f' %f1_lr)
```

```
accuracy_random_Forest : 0.840
precision_random_Forest : 0.278
recall_random_Forest : 0.188
f1-score_random_Forest : 0.225
```

```python
# confusion matrix logistic regression
cm = confusion_matrix(y_testing, y_pred_lr)
p = sns.heatmap(pd.DataFrame(cm), annot=True, cmap="YlGnBu" ,fmt='g')
plt.title('confusion matrix for logistic regression')
plt.xlabel('Predicted Label')
plt.ylabel('actual label')
plt.show()
```

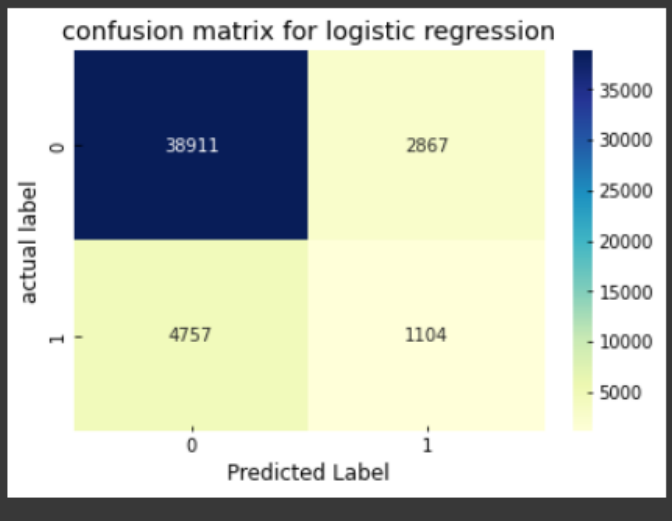

- **analisis overfitting pada model**

Model Random Forest

```
[80] # analisis model random forrest
     rf_testing = accuracy_score(y_testing, y_pred_rf)
     rf_training = accuracy_score(clf.predict(data_training), y_training)

     print("analisis random forrest")
     print("akurasi pada data training " , rf_training)
     print("akurasi pada data testing : ", rf_testing)
```

```
analisis random forrest
akurasi pada data training  0.8030315133602268
akurasi pada data testing :  0.6935074203908562
```

Model naive bayes

```
# analisis model naive bayes
nb_testing = accuracy_score(y_testing, y_pred_nb)
nb_training = accuracy_score(nb.predict(data_training), y_training)

print("analisis naive bayes")
print("akurasi pada data training " , nb_training)
print("akurasi pada data testing : ", nb_testing)
```

```
analisis naive bayes
akurasi pada data training  0.7844856279373195
akurasi pada data testing :  0.6395600243497974
```

Model Logistic Regression

```
# analisis model logistic regression
lr_testing = accuracy_score(y_testing, y_pred_lr)
lr_training = accuracy_score(regressor.predict(data_training), y_training)

print("analisis logistic regression")
print("akurasi pada data training " , lr_training)
print("akurasi pada data testing : ", lr_testing)
```

```
analisis logistic regression
akurasi pada data training  0.5620947664123763
akurasi pada data testing :  0.839963055479754
```

Evaluasi model dari eksperimen 2

- **nilai akurasi model, nilai precision model, nilai recall model, nilai f-1 model dan confusion matrix**

Model random forest

```
# random forest
accuracy_rf = accuracy_score(y_testing, y_pred_rf)
precision_rf = precision_score(y_testing, y_pred_rf)
recall_rf =  recall_score(y_testing, y_pred_rf)
f1_rf = f1_score(y_testing, y_pred_rf)
print("evaluasi random forrest")
print('accuracy_random_Forest : %.3f' %accuracy_rf)
print('precision_random_Forest : %.3f' %precision_rf)
print('recall_random_Forest : %.3f' %recall_rf)
print('f1-score_random_Forest : %.3f' %f1_rf)
```

```
evaluasi random forrest
accuracy_random_Forest : 0.690
precision_random_Forest : 0.275
recall_random_Forest : 0.932
f1-score_random_Forest : 0.425
```

```
# confusion matrix random forrest
cm = confusion_matrix(y_testing, y_pred_rf)
p = sns.heatmap(pd.DataFrame(cm), annot=True, cmap="YlGnBu" ,fmt='g')
plt.title('confusion matrix for random forrest')
plt.xlabel('Predicted Label')
plt.ylabel('actual label')
plt.show()
```

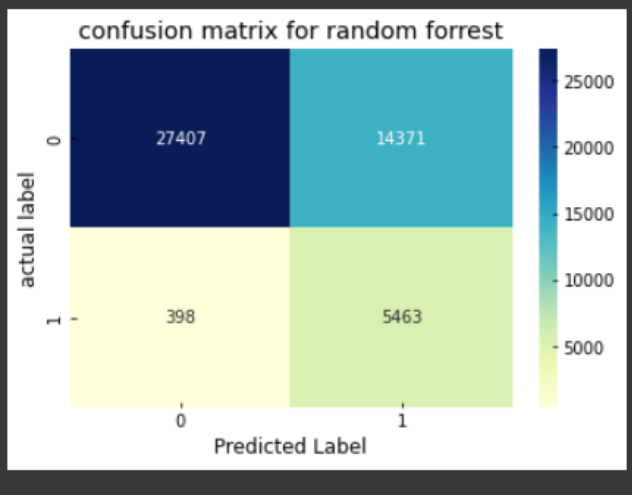

Model naive bayes

```
# naive bayes
accuracy_nb = accuracy_score(y_testing, y_pred_nb)
precision_nb = precision_score(y_testing, y_pred_nb)
recall_nb =  recall_score(y_testing, y_pred_nb)
f1_nb = f1_score(y_testing, y_pred_nb)
print("evaluasi naive bayes")
print('accuracy_random_Forest : %.3f' %accuracy_nb)
print('precision_random_Forest : %.3f' %precision_nb)
print('recall_random_Forest : %.3f' %recall_nb)
print('f1-score_random_Forest : %.3f' %f1_nb)
```

```
evaluasi naive bayes
accuracy_random_Forest : 0.582
precision_random_Forest : 0.227
recall_random_Forest : 0.996
f1-score_random_Forest : 0.370
```

```
# confusion matrix naive bayes
cm = confusion_matrix(y_testing, y_pred_nb)
p = sns.heatmap(pd.DataFrame(cm), annot=True, cmap="YlGnBu" ,fmt='g')
plt.title('confusion matrix for naive bayes')
plt.xlabel('Predicted Label')
plt.ylabel('actual label')
plt.show()
```

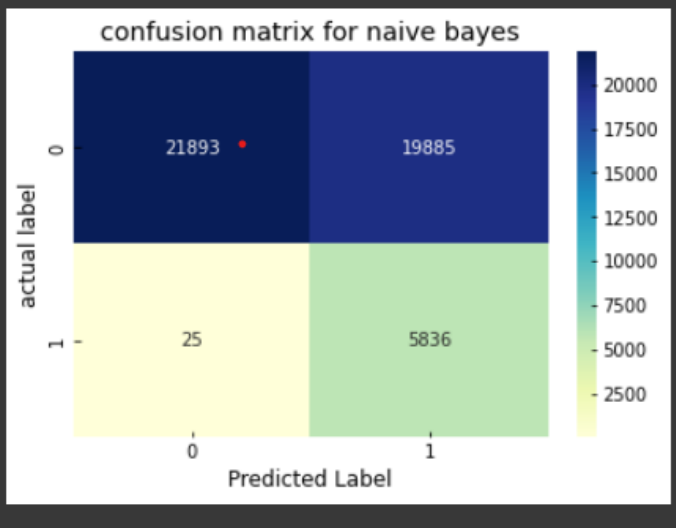

Model logistic regression

```
[74] # logistic regression
accuracy_lr = accuracy_score(y_testing, y_pred_lr)
precision_lr = precision_score(y_testing, y_pred_lr)
recall_lr =  recall_score(y_testing, y_pred_lr)
f1_lr = f1_score(y_testing, y_pred_lr)
print("evaluasi logistic regression")
print('accuracy_random_Forest : %.3f' %accuracy_lr)
print('precision_random_Forest : %.3f' %precision_lr)
print('recall_random_Forest : %.3f' %recall_lr)
print('f1-score_random_Forest : %.3f' %f1_lr)
```

```
evaluasi logistic regression
accuracy_random_Forest : 0.840
precision_random_Forest : 0.277
recall_random_Forest : 0.189
f1-score_random_Forest : 0.225
```

```
# confusion matrix logistic regression
cm = confusion_matrix(y_testing, y_pred_lr)
p = sns.heatmap(pd.DataFrame(cm), annot=True, cmap="YlGnBu" ,fmt='g')
plt.title('confusion matrix for logistic regression')
plt.xlabel('Predicted Label')
plt.ylabel('actual label')
plt.show()
```

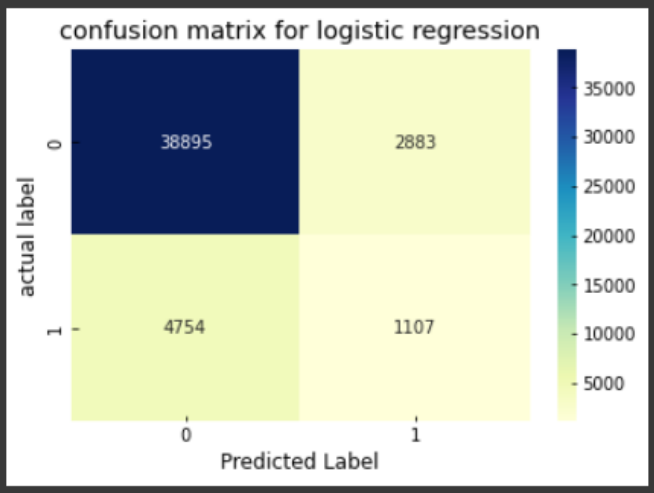

- **analisis overfitting pada model**

overfitting terjadi apabila model dianggap lebih optimal dalam memprediksi data training dan tidak cukup akurat dalam memprediksi data testing. salah satu cara yang kita lakukan adalah membandingkan akurasi model dalam memprediksi data training dan testing.

Random Forest

```
[77] # analisis model random forrest
     rf_testing = accuracy_score(y_testing, y_pred_rf)
     rf_training = accuracy_score(clf.predict(data_training), y_training)

     print("analisis random forrest")
     print("akurasi pada data training " , rf_training)
     print("akurasi pada data testing : ", rf_testing)
```

```
analisis random forrest
akurasi pada data training  0.8004628439187452
akurasi pada data testing :  0.6899808980037364
```

Naive Bayes

```
# analisis model naive bayes
nb_testing = accuracy_score(y_testing, y_pred_nb)
nb_training = accuracy_score(nb.predict(data_training), y_training)

print("analisis naive bayes")
print("akurasi pada data training " , nb_training)
print("akurasi pada data valid : ", nb_testing)
```

```
analisis naive bayes
akurasi pada data training  0.7362218222336505
akurasi pada data valid :  0.5820651147169336
```

Logistic Regression

```
# analisis model logistic regression
lr_testing = accuracy_score(y_testing, y_pred_lr)
lr_training = accuracy_score(regressor.predict(data_training), y_training)

print("analisis logistic regression")
print("akurasi pada data training " , lr_training)
print("akurasi pada data valid : ", lr_testing)
```

```
analisis logistic regression
akurasi pada data training  0.549670009428302
akurasi pada data valid :  0.8396901698188459
```

Kesimpulan

- Eksperimen 1 :
    - mengelola nilai yang kosong (missing values) : dilakukan pembuangan pada baris tersebut.

    - label data training yang tidak setara (imbalanced dataset) : dilakukan oversampling supaya data yang setara.
- Eksperimen 2 :
    - mengelola nilai yang kosong (missing values) : dilakukan pengisian nilai pada baris tersebut. pengisian nilai modus untuk data yang bersifat kategorial dan pengisian nilai rata-rata (mean) untuk data diskrit/kontinu.
    - label data training yang tidak setara (imbalanced dataset) : dilakukan undersampling supaya data yang setara.

Hasil analisis

memilih model terbaik berdasarkan nilai akurasi model

	Eksperimen 1		Eksperimen 2	
Model	akurasi di training	akurasi di testing	akurasi di training	akurasi di testing
Random Forest	0.803	0.693	0.8	0.689
Naive bayes	0.784	0.639	0.736	0.582
Logistic regression	0562	0.839	0.549	0.839

berdasarkan hasil akurasi dari ketiga model yang digunakan (random forest, naive bayes, logistic regression), model yang paling optimal untuk digunakan dalam memprediksi data training pada kasus kami adalah dengan menggunakan model logistic regression. Untuk kedua eksperimen diatas, cenderung menghasilkan pola yang sama pada nilai akurasi yang dihasilkan. Dimana untuk model random forest dan naive bayes, akurasi pada data training cenderung lebih besar dibandingkan akurasi pada data testing. berbeda dengan model logistic regression, yang akurasi pada data testingnya, jauh lebih besar dibandingkan akurasi pada data training.

memilih model yang terbaik berdasarkan nilai recall (recall adalah seberapa baik model kami dalam memprediksi kelas positif dengan benar)

berdasarkan hasil analisis nilai-nilai pada confusion matrix masing-masing model, khususnya pada kasus percobaan kami, yaitu memprediksi apakah pelanggan tertarik untuk membeli kendaraan baru atau tidak berdasarkan data pelanggan di dealer.
Dengan asumsi kami bahwa hasil prediksi label nantinya digunakan untuk menyusun strategi penjualan kendaraan kedepannya. kami merasa kebenaran dalam memprediksi pelanggan yang tertarik, memiliki bobot / prioritas yang lebih tinggi dibandingkan kebenaran dalam memprediksi pelanggan yang tidak tertarik. Dikarenakan bagi dealer, untuk melakukan penjualan dengan efektif, dealer pastinya hanya akan menjual kendaraannya pada pelanggan yang memang tertarik, tidak perlu membuang waktu untuk menjual kendaraan kepada pelanggan yang tidak tertarik. sehingga memilih model yang memiliki nilai recall yang tinggi dapat dijadikan pertimbangan nantinya dalam memilih model mana yang paling bagus dalam memprediksi pelanggan yang tertarik.

Nilai recall untuk masing-masing model

	Eksperimen 1	Eksperimen 2
Model		
random forest	0.928	0.932
naive bayes	0.975	0.996
logistic regression	0.188	0.189

Sehingga untuk model yang paling bagus dalam memprediksi pelanggan yang tertarik, merupakan model naive bayes.

Lampiran

link presentasi (youtube) : https://youtu.be/eZckDi7OihE

link drive (jika diperlukan) :
https://drive.google.com/drive/folders/1p3vIautSB3Cu3R8w3yxU7C1GtM4jtt4g?usp=sharing